Rapport du projet de

Machine learning appliquée à la finance

BEN AMMAR KHAOULA
M1 ECOFIQ

Prédiction des litiges consommateurs

Contexte général

Dans un monde régi par une interconnexion croissante entre les individus, les institutions et les technologies, la voix du consommateur occupe désormais une place stratégique dans les dynamiques économiques contemporaines. L'essor des outils numériques et des plateformes de médiation a profondément transformé les rapports entre les usagers et les entreprises, en rendant visibles, traçables et analysables des millions d'interactions portant sur la qualité des produits et des services rendus.

Dans ce paysage en mutation, les plaintes des consommateurs constituent bien plus qu'un simple indicateur de mécontentement : elles représentent un signal faible, mais riche de sens, sur les failles systémiques, les attentes insatisfaites et les tensions latentes au sein des marchés.

L'analyse massive de ces données transactionnelles et relationnelles, autrefois négligées, s'impose aujourd'hui comme un levier incontournable de connaissance client, d'amélioration des performances opérationnelles et de conformité réglementaire. Les entreprises, tout comme les autorités de supervision, s'efforcent de décrypter les comportements post-achat afin d'anticiper les risques, d'optimiser la gestion des réclamations, et de restaurer la confiance dans un écosystème souvent perçu comme asymétrique.

Dans cette optique, les techniques de science des données et d'apprentissage automatique apparaissent comme des outils méthodologiquement puissants, capables de transformer un corpus de plaintes textuelles et structurées en informations exploitables pour la prise de décision stratégique.

Au cœur de cette logique prédictive se trouve une problématique particulièrement sensible : celle de la contestation. Lorsqu'un consommateur exprime une insatisfaction, la manière dont il reçoit et perçoit la réponse de l'entreprise peut conditionner l'escalade du conflit. Être en mesure de prédire si

une réclamation donnera lieu à une remise en cause du traitement proposé, c'est donner aux organisations les moyens d'adapter leur communication, d'allouer leurs ressources de médiation de façon ciblée, et de prévenir les contentieux.

Cette capacité d'anticipation devient d'autant plus cruciale dans des secteurs comme la finance, où la complexité des produits et la rigueur réglementaire exigent un traitement rigoureux, équitable et transparent des litiges.

Ainsi, dans le cadre de ce projet, il s'agira de mobiliser un ensemble de méthodes issues de l'intelligence artificielle pour construire un modèle prédictif à partir de données réelles de plaintes, dans le but de détecter les facteurs expliquant la probabilité de contestation d'une plainte par un consommateur.

Introduction

Dans le cadre de ce projet, nous explorons les possibilités offertes par l'apprentissage automatique pour prédire les contestations de plaintes de consommateurs, en nous appuyant sur un jeu de données fourni par la Consumer Financial Protection Bureau (CFPB), une institution fédérale américaine chargée de la protection des usagers des services financiers. Cette base de données regroupe des plaintes déposées par des particuliers à l'encontre de diverses entités financières, couvrant une grande variété de problématiques : comptes courants, prêts hypothécaires, cartes de crédit, erreurs de notation de crédit, etc.

Chaque plainte est accompagnée de métadonnées détaillées telles que le type de produit, la nature du problème, le mode de soumission, la réponse de l'entreprise, ainsi qu'une variable cible binaire indiquant si le consommateur a contesté ou non la réponse reçue. L'objectif de notre étude est de construire un modèle prédictif supervisé capable d'estimer, à partir de ces caractéristiques, la probabilité de contestation d'une plainte, afin d'anticiper les cas à risque et d'améliorer les stratégies de médiation client.

Le pipeline mis en place comprend plusieurs étapes fondamentales : le prétraitement des données (nettoyage des valeurs manquantes, encodage des variables catégorielles via One-Hot Encoding) et un enrichissement des données textuelles issues de la colonne "consumer_complaint_narrative", à partir de laquelle ont été extraits des indicateurs comme la longueur du texte, le nombre de mots uniques ou la présence d'un récit.

Ensuite, nous avons appliqué la technique SMOTE (Synthetic Minority Over-sampling Technique) pour rééquilibrer les classes, la variable cible étant très déséquilibrée entre plaintes contestées et non contestées. Cette étape a permis de rendre l'apprentissage plus représentatif.

Trois modèles d'apprentissage supervisé ont été implémentés et comparés : le Random Forest Classifier, reconnu pour sa robustesse et son interprétabilité ; le Gradient Boosting Classifier, réputé pour sa haute précision dans les jeux de données déséquilibrés ; et enfin, le K-Nearest Neighbors (KNN), basé sur la similarité entre observations, intégré dans un pipeline avec normalisation préalable.

Une optimisation des hyperparamètres a ensuite été réalisée sur le modèle Random Forest à l'aide de GridSearchCV afin d'en améliorer les performances.

Les performances des modèles ont été évaluées à l'aide de plusieurs métriques : l'accuracy, la précision, le rappel et l'AUC-ROC. Des visualisations telles que les matrices de confusion et les courbes ROC ont également été produites afin de mieux analyser la qualité des prédictions.

Cette démarche vise non seulement à identifier le meilleur algorithme pour cette tâche, mais aussi à mieux comprendre les facteurs expliquant les comportements contestataires des clients. Elle s'inscrit dans une volonté d'exploitation stratégique de la donnée pour améliorer les processus de traitement des réclamations dans le secteur financier.

Objectif :

L'objectif principal de ce projet est de concevoir un modèle de classification supervisée capable de prédire, à partir des caractéristiques disponibles dans les plaintes enregistrées par la Consumer Financial Protection Bureau (CFPB), si un consommateur est susceptible de contester ou non la réponse apportée par l'entreprise mise en cause. Cette tâche prédictive repose sur une problématique à la croisée de l'analyse comportementale, du traitement de texte et de l'intelligence artificielle appliquée.

Pour y parvenir, une approche complète a été mise en place, incluant le nettoyage des données, l'encodage des variables catégorielles, et surtout l'enrichissement des données textuelles via des indicateurs extraits du récit de la plainte (longueur, nombre de mots uniques, présence de narration). De plus, l'utilisation de la méthode SMOTE a permis de rééquilibrer la distribution des classes pour améliorer la détection des cas minoritaires.

Trois modèles d'apprentissage automatique ont été mobilisés : Random Forest, K-Nearest Neighbors (intégré dans un pipeline avec normalisation), et Gradient Boosting. Ces modèles ont été comparés selon plusieurs métriques (précision, rappel, AUC, accuracy) et des visualisations comme les matrices de confusion ou les courbes ROC ont été générées pour évaluer leurs performances. Le modèle Random Forest a en outre fait l'objet d'une optimisation des hyperparamètres via GridSearchCV.

L'enjeu de ce projet est double : d'un côté, améliorer la capacité des entreprises à anticiper les litiges potentiels pour adapter leur gestion des réclamations ; de l'autre, fournir une analyse fine des facteurs influençant le comportement contestataire des clients, dans une perspective de transparence, d'efficacité et de régulation éthique du secteur financier.

Validation de la base de données

La base de données utilisée dans ce projet provient du Consumer Complaint Database, une ressource ouverte mise à disposition par la Consumer Financial Protection Bureau (CFPB). Cette base recense des plaintes de consommateurs portant sur une grande variété de produits et services financiers, tels que les cartes de crédit, les prêts étudiants, les hypothèques, les comptes bancaires, ou encore les services de recouvrement de créances. Chaque plainte est accompagnée d'un ensemble de métadonnées détaillées, incluant le type de

produit concerné, la nature du problème, la date de réception, le canal de soumission, la réponse fournie par l'entreprise, ainsi qu'une variable cible précisant si le consommateur a contesté ou non la réponse apportée.

Cette base de données a été choisie pour la richesse et la pertinence de ses informations, qui en font un support particulièrement adapté à notre objectif de modélisation prédictive. Elle présente à la fois des données structurées, exploitables par des algorithmes classiques, et des données textuelles non structurées notamment les récits des consommateurs dans le champ "consumer_complaint_narrative" qui offrent des opportunités intéressantes pour le feature engineering.

Lors de la phase de validation, un ensemble de vérifications a été effectué afin de s'assurer de la qualité et de l'exploitabilité des données : identification et traitement des valeurs manquantes, sélection des variables pertinentes, et nettoyage des doublons éventuels. Par ailleurs, des variables numériques dérivées du texte ont été créées afin de quantifier l'engagement du consommateur (comme la longueur du récit ou le nombre de mots uniques). La distribution fortement déséquilibrée de la variable cible a également été prise en compte par l'application de la méthode SMOTE, permettant d'équilibrer les classes lors de l'entraînement des modèles.

Ainsi, la base de données utilisée dans ce projet ne se limite pas à une simple collection de plaintes : elle constitue un corpus riche, diversifié et cohérent, offrant un terrain d'expérimentation optimal pour le développement de modèles de classification robustes et interprétables.

Création d'un Notebook :

J’ai créé un Notebook Kaggle pour ce projet, et les données ont été importées dans le Notebook.

Ensuite, les étapes suivantes ont été réalisées pour explorer et traiter les données.

Exploration de la base de données :

L’analyse a commencé par une phase d’exploration approfondie du jeu de données fourni par la **Consumer Financial Protection Bureau (CFPB)**, accessible via l’API Kaggle. Ce jeu de données constitue un registre structuré regroupant des réclamations de consommateurs à l’encontre d’institutions financières américaines. Il couvre une large gamme de produits et services, incluant les prêts à la consommation, les cartes de crédit, les hypothèques, les services de recouvrement, entre autres. Chaque plainte est enrichie de métadonnées détaillées concernant le contexte de la réclamation, la réponse apportée par l’entreprise, ainsi que la réaction finale du consommateur.

La phase initiale d’inspection visuelle a permis d’examiner les premières lignes du fichier, d’identifier les types de variables présentes, de sélectionner les colonnes pertinentes pour l’analyse, et de détecter les valeurs manquantes. Afin de faciliter le prototypage et d’optimiser les performances en phase d’expérimentation, un sous-échantillon représentatif de 1 000 observations a été extrait. Les colonnes comportant des données manquantes ont été conservées, les valeurs nulles ayant été imputées par la chaîne de caractères "Unknown", ce qui a permis de maintenir l’intégralité des observations sans introduire de biais liés à une suppression.

L'analyse exploratoire s'est particulièrement focalisée sur la variable cible, **consumer_disputed**, qui indique si la plainte a été contestée (valeur 1) ou non (valeur 0). La distribution des classes a été visualisée sous forme d'histogramme, mettant en évidence un fort déséquilibre, phénomène courant dans les jeux de données réels et pouvant nuire à la qualité des modèles prédictifs. Pour pallier cet effet, une méthode de rééchantillonnage, la technique SMOTE (Synthetic Minority Over-sampling Technique), a été appliquée exclusivement sur le jeu d'entraînement. Cette technique permet de générer artificiellement des exemples supplémentaires de la classe minoritaire, améliorant ainsi l'équilibre des classes et la capacité des modèles à détecter les cas de contestation.

Cette phase d'exploration a donc permis de préparer les données de manière rigoureuse, en posant les bases d'un apprentissage supervisé efficace et robuste face aux défis posés par la nature hétérogène et déséquilibrée des données.

Prétraitement des données :

Au-delà des opérations classiques de nettoyage, une phase de **feature engineering** a été réalisée afin d'enrichir le jeu de données initial. En particulier, à partir de la colonne textuelle contenant le récit détaillé du consommateur (**consumer_complaint_narrative**), plusieurs variables numériques ont été extraites : la longueur du texte en nombre de mots, le nombre de mots uniques, le nombre total de caractères, ainsi qu'une variable binaire indiquant la présence ou l'absence de narration. Ces indicateurs permettent de quantifier l'intensité et la richesse descriptive du consommateur, ce qui peut être corrélé à un engagement émotionnel plus prononcé une hypothèse jugée pertinente pour la prédiction des contestations.

Les variables catégorielles restantes ont été traitées via un encodage **one-hot**, avec un ajustement dynamique du paramètre **sparse_output** selon la version utilisée de la bibliothèque scikit-learn, afin d'optimiser la gestion de la mémoire et l'efficacité du traitement. L'ensemble des variables encodées a ensuite été fusionné avec les variables numériques nouvellement créées, constituant ainsi la matrice finale destinée à l'apprentissage automatique.

Par ailleurs, certaines variables jugées non pertinentes ou redondantes ont été exclues, notamment les identifiants uniques tels que **complaint_id**, ainsi que les données brutes comme les codes postaux. Ces derniers ont été agrégés à un niveau régional afin de préserver l'information géographique tout en limitant la granularité excessive susceptible de nuire à la généralisation des modèles.

Cette étape de transformation a permis de disposer d'un jeu de données à la fois riche, structuré et prêt à être exploité dans les algorithmes de classification supervisée.

Modélisation et expérimentation comparative

La phase de modélisation constitue le cœur opérationnel de ce projet, visant à entraîner et tester trois algorithmes de classification supervisée sur la tâche de prédiction des contestations potentielles des consommateurs à partir des données financières.

Le premier algorithme retenu est le **Random Forest Classifier**, une méthode d'ensemble construite à partir de multiples arbres de décision entraînés sur des sous-échantillons aléatoires du jeu de données. Ce modèle est reconnu pour sa robustesse face au sur apprentissage et sa capacité à modéliser des relations non linéaires complexes.

Le second modèle utilisé est le **Gradient Boosting Classifier**, un algorithme basé sur l'agrégation séquentielle de modèles faibles (arbres peu profonds), où chaque itération corrige les erreurs de la précédente. Cette méthode est adaptée aux tâches de classification, notamment dans les contextes de classes déséquilibrées.

Enfin, le troisième modèle est le **K-Nearest Neighbors (KNN)**, un algorithme non paramétrique fondé sur la proximité dans l'espace vectoriel. Il est intégré dans un pipeline avec une normalisation préalable des variables numériques à l'aide d'un StandardScaler, afin de neutraliser les effets liés à l'échelle des données.

Chaque modèle a été entraîné sur un échantillon d'apprentissage rééchantillonné via la méthode SMOTE (Synthetic Minority Over-sampling Technique), permettant d'équilibrer la proportion des classes en générant artificiellement des observations de la classe minoritaire (plaintes contestées). Les modèles ont ensuite été évalués sur un échantillon de test non modifié afin d'assurer l'objectivité des résultats.

Les performances des modèles ont été mesurées à l'aide de plusieurs métriques : l'accuracy (taux de bonnes classifications global), la précision, le rappel, et l'AUC-ROC (aire sous la courbe ROC). Des visualisations telles que les matrices de confusion et les courbes ROC ont également été produites pour faciliter la lecture des résultats.

L'analyse comparative est un outil indispensable pour garantir la qualité, la pertinence et la robustesse des solutions d'apprentissage automatique développées, notamment dans des domaines sensibles comme la prédiction des contestations des consommateurs.

Optimisation des performances

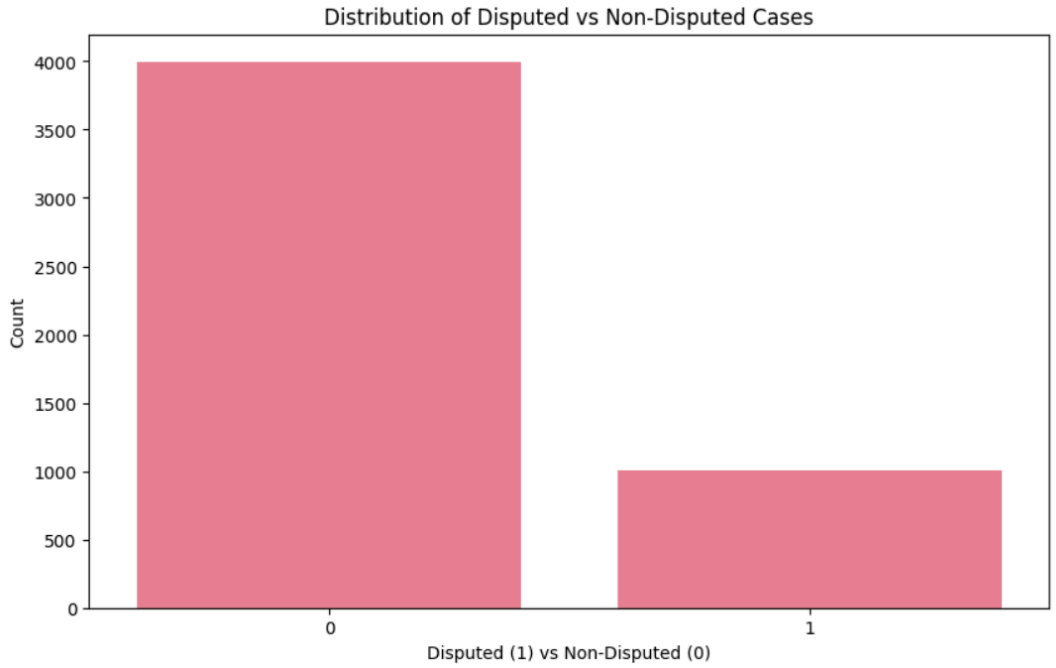
Pour optimiser les performances du modèle Random Forest, une recherche d'hyper paramètres par validation croisée (GridSearchCV) a été mise en place. Cette étape a permis d'explorer diverses configurations, notamment le nombre d'arbres dans la forêt (`n_estimators`), la profondeur maximale des arbres (`max_depth`), ainsi que la taille minimale des échantillons requis pour diviser un nœud (`min_samples_split`). L'emploi systématique de la validation croisée a assuré la robustesse du modèle en limitant les risques de sur apprentissage tout en garantissant une bonne généralisation.

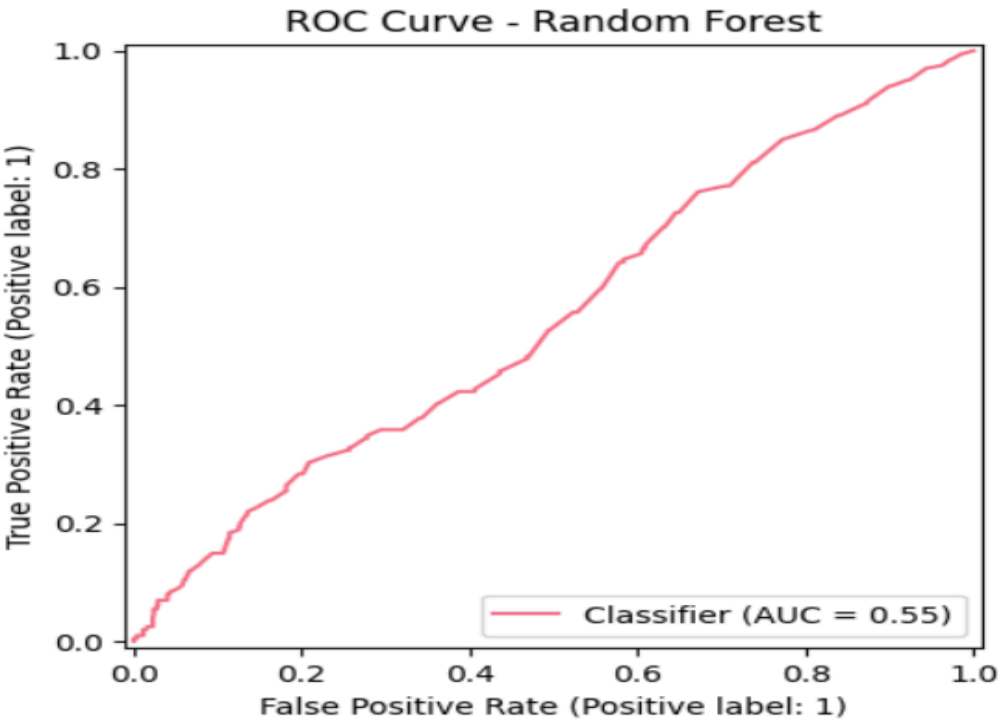
Le modèle Random Forest ainsi optimisé a été entraîné sur les données rééquilibrées par SMOTE, ce qui a renforcé sa capacité à détecter les plaintes contestées, particulièrement en termes de rappel et d'aire sous la courbe ROC (AUC). Ces métriques cruciales confirment l'efficacité du modèle dans un contexte où la détection précise des cas à risque est primordiale, justifiant son adoption pour des applications opérationnelles visant à anticiper et gérer proactivement les litiges.

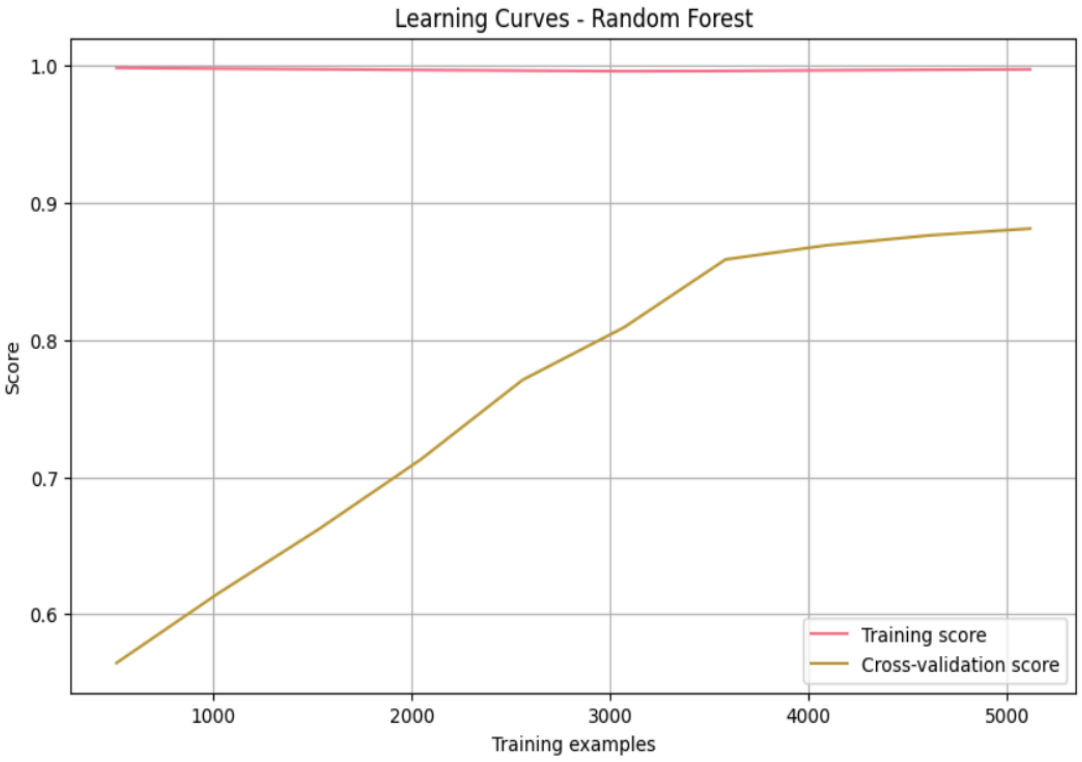
Un avantage notable de ce modèle réside dans sa faculté à quantifier l'importance relative des variables explicatives. L'analyse des scores d'importance a révélé que plusieurs caractéristiques extraites du récit textuel du consommateur telles que la longueur du texte (nombre de mots), la diversité lexicale (nombre de mots uniques), ainsi que la présence ou non de narration jouent un rôle clé dans la prédiction de la contestation. Par ailleurs, certaines variables catégorielles, notamment le canal de soumission de la plainte (`submitted_via`) et la nature de la réponse fournie par l'entreprise, se sont également distinguées comme des facteurs déterminants. Ces insights offrent non seulement des pistes d'amélioration analytique, mais aussi des leviers stratégiques précieux pour les organisations souhaitant optimiser leur gestion des réclamations et renforcer la satisfaction client.

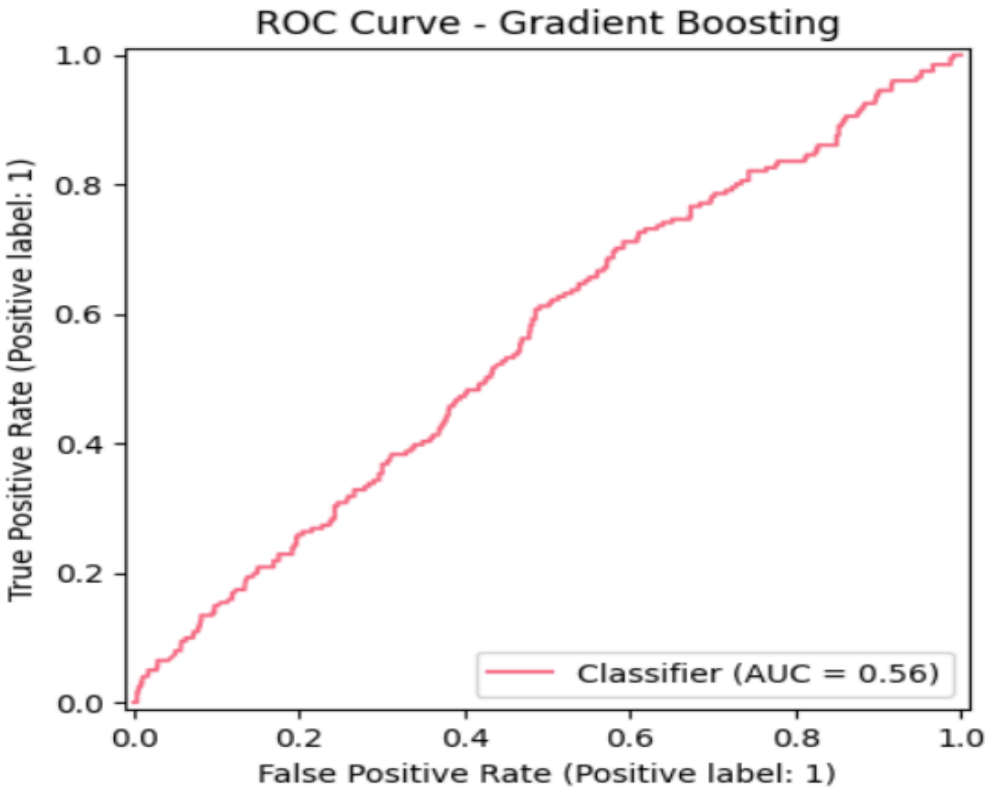
Visualisations :

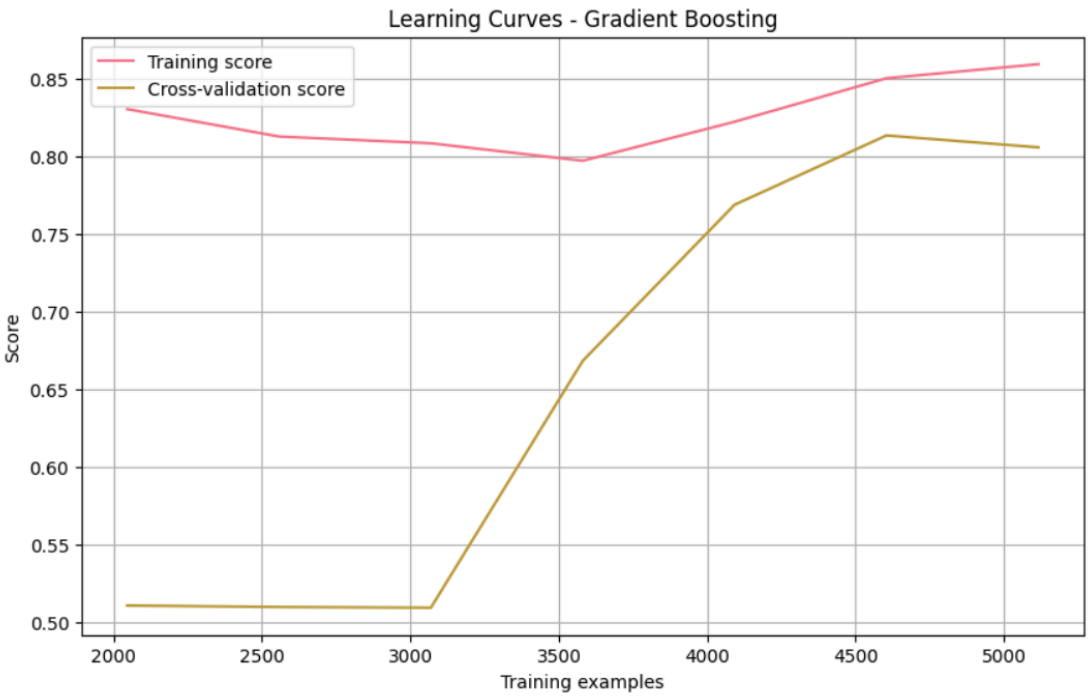
Voici quelques visualisations :

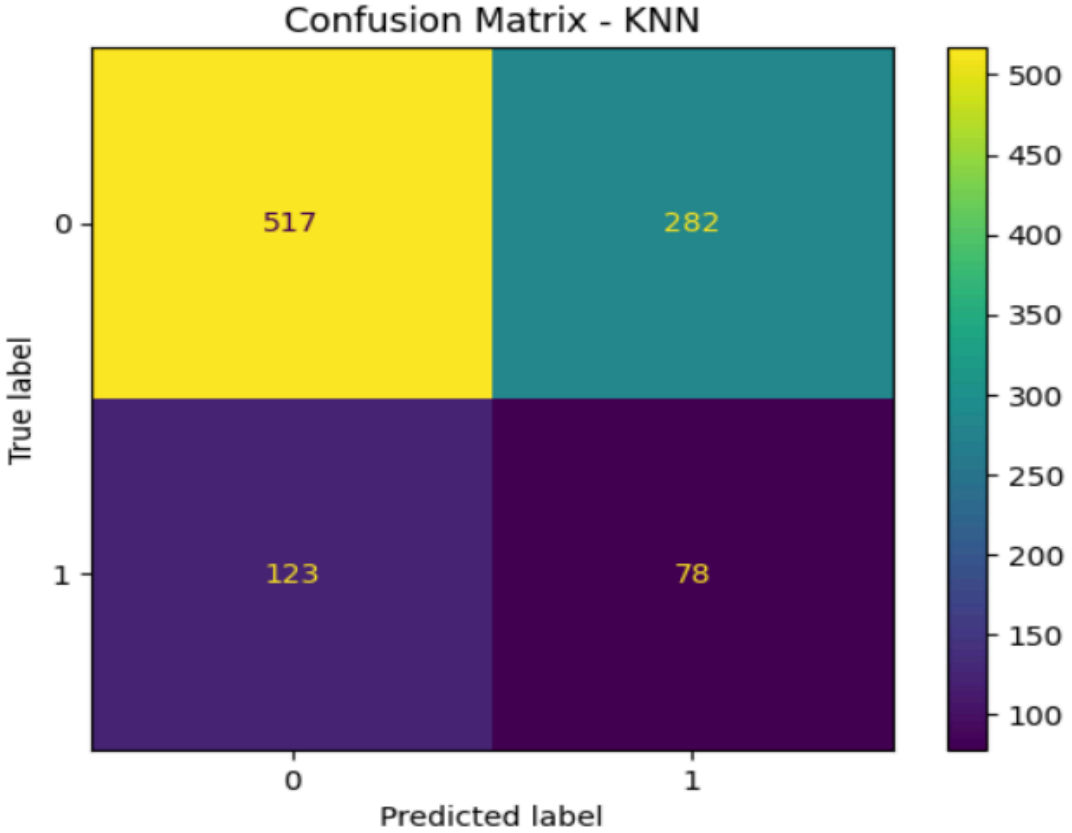


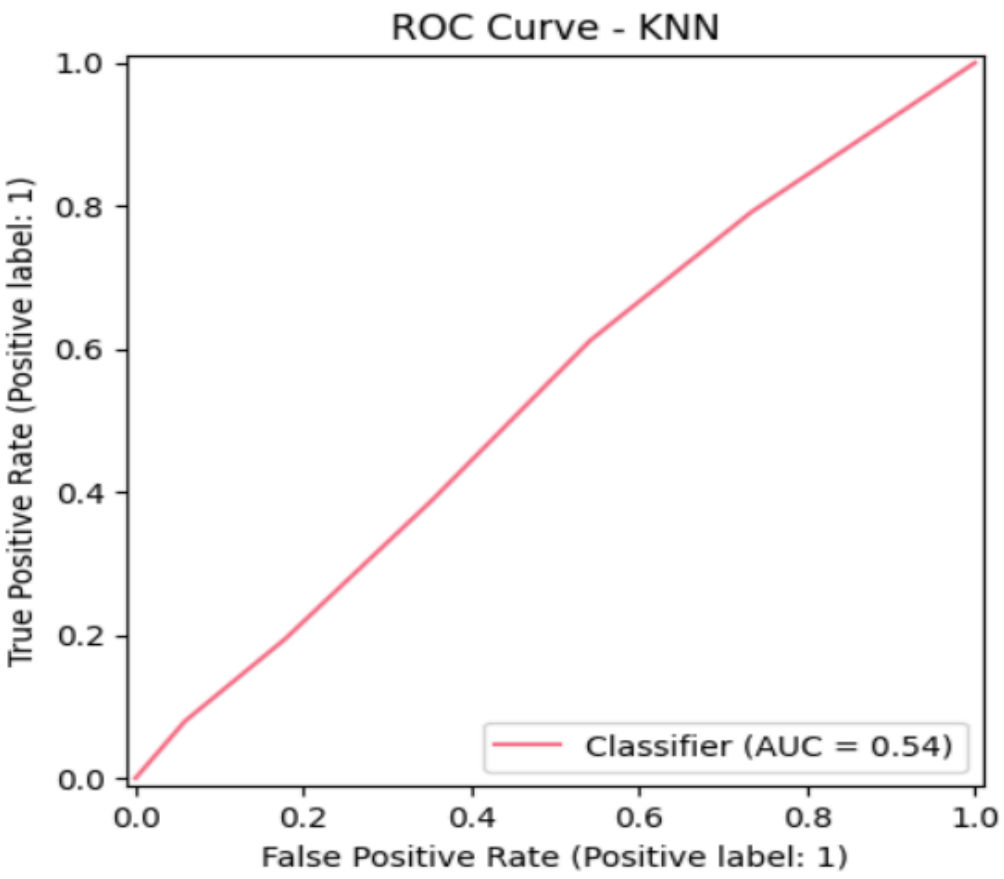


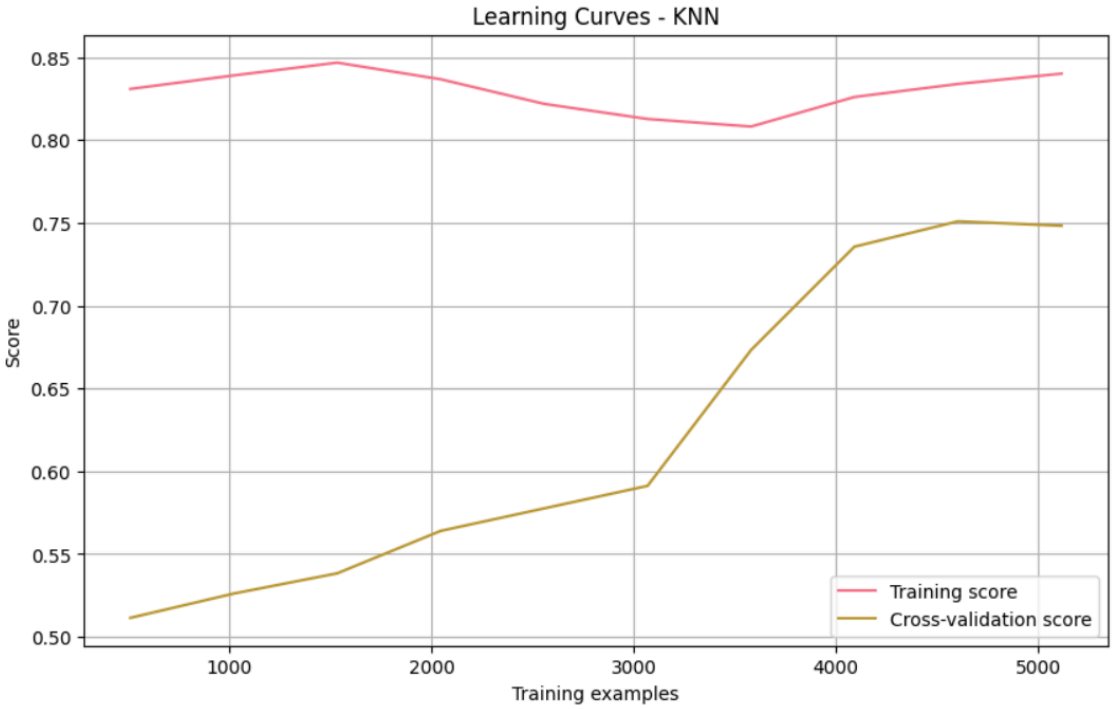

Learning Curves - Random Forest
Score
Training examples
Training score
Cross-validation score
1.0
0.9
0.8
0.7
0.6
1000
2000
3000
4000
5000


ROC Curve - Gradient Boosting
True Positive Rate (Positive label: 1)
False Positive Rate (Positive label: 1)
Classifier (AUC = 0.56)
0.0
0.2
0.4
0.6
0.8
1.0


Learning Curves - Gradient Boosting
Training score
Cross-validation score
Score
Training examples
0.85
0.80
0.75
0.70
0.65
0.60
0.55
0.50
2000
2500
3000
3500
4000
4500
5000


Confusion Matrix - KNN
517
282
123
78
True label
Predicted label
0
1
0
1
500
450
400
350
300
250
200
150
100


ROC Curve - KNN
True Positive Rate (Positive label: 1)
False Positive Rate (Positive label: 1)
Classifier (AUC = 0.54)
0.0
0.2
0.4
0.6
0.8
1.0


Learning Curves - KNN
Score
Training examples
Training score
Cross-validation score
0.50
0.55
0.60
0.65
0.70
0.75
0.80
0.85
1000
2000
3000
4000
5000

Interprétation des résultats :

L'analyse comparative des performances des trois algorithmes de classification met en lumière des caractéristiques et avantages propres à chacun, en lien avec leur approche méthodologique et leur adaptation aux spécificités du jeu de données.

Le Random Forest Classifier se distingue par sa robustesse face aux données hétérogènes et bruitées, ainsi que par sa capacité à gérer efficacement un grand nombre de variables catégorielles encodées. Sa structure en forêt d'arbres décisionnels indépendants lui confère une excellente capacité de généralisation, limitant les risques de surapprentissage. De plus, sa fonction intrinsèque d'estimation de l'importance des variables facilite l'interprétation des facteurs influençant la contestation, ce qui apporte une transparence précieuse pour les décideurs.

Le Gradient Boosting Classifier montre une puissance prédictive élevée, notamment dans la détection des plaintes contestées, ce qui se traduit par un rappel souvent supérieur à celui des autres modèles. Cette méthode procède par correction itérative des erreurs, affinant ainsi son apprentissage sur des cas complexes ou atypiques. Bien qu'elle nécessite un réglage précis des hyperparamètres et soit plus gourmande en ressources, elle est particulièrement efficace sur des données déséquilibrées, ce qui la rend adaptée à la détection fine des situations à risque.

Le K-Nearest Neighbors (KNN), malgré des performances globales inférieures, présente des atouts spécifiques. Sa simplicité conceptuelle et son fonctionnement basé sur la proximité locale en font un bon outil de référence pour une analyse exploratoire. Intégré dans un pipeline avec normalisation, il corrige les effets d'échelle et gagne en stabilité. Il offre également une interprétabilité locale, où chaque prédiction peut être expliquée par les

observations voisines, ce qui est utile pour des analyses qualitatives ou des cas d'usage ponctuels.

En conclusion, ces modèles se complètent par leurs forces respectives : le Random Forest combine robustesse, performance et interprétabilité ; le Gradient Boosting excelle dans la précision sur les cas minoritaires ; et le KNN apporte une approche simple et locale. Cette diversité suggère qu'une stratégie hybride, ou un système d'ensemble combinant ces modèles, pourrait permettre d'améliorer encore la qualité de la prédiction des contestations.

Conclusion :

Ce projet a permis de concevoir, d'implémenter et d'évaluer un pipeline complet d'apprentissage automatique appliqué à une problématique concrète du secteur financier : la prédiction des litiges potentiels à partir des données de réclamations de consommateurs. L'exploitation du jeu de données issu de la *Consumer Financial Protection Bureau* a mis en évidence l'importance d'un traitement rigoureux, tant en termes de nettoyage que de transformation des variables, pour permettre aux modèles de capturer des signaux pertinents.

La comparaison de trois approches algorithmiques Random Forest, Gradient Boosting, et K-Nearest Neighbors a révélé que les modèles à base d'arbres, notamment lorsqu'ils sont associés à une optimisation fine de leurs paramètres et à un rééquilibrage des classes par SMOTE, offrent les meilleures garanties de performance. Le modèle Random Forest, optimisé par recherche de grille, s'est

distingué tant par sa précision que par sa capacité à identifier les observations minoritaires, tout en offrant une interprétabilité bienvenue.

Au-delà des résultats techniques, ce travail illustre le potentiel des méthodes de machine learning dans l'amélioration des processus décisionnels liés à la relation client. Il ouvre la voie à des applications concrètes, comme le développement d'outils d'alerte pour les équipes de support client, la priorisation des dossiers sensibles, ou encore l'élaboration de politiques de réponse adaptées à la typologie des consommateurs. Néanmoins, il convient de souligner que toute mise en œuvre opérationnelle nécessitera une validation sur des volumes plus importants, une mise à jour continue des modèles, ainsi qu'une vigilance accrue quant aux biais algorithmiques susceptibles de se manifester dans des contextes sensibles tels que celui de la protection des consommateurs.

En somme, cette étude pose les fondations d'une démarche rigoureuse et réplicable, susceptible d'être étendue à d'autres bases de données ou à d'autres secteurs, et ouvre des perspectives intéressantes pour la recherche appliquée en intelligence artificielle au service de la satisfaction et de la fidélisation client.

Perspectives futures :

Ce projet ouvre la voie à plusieurs prolongements intéressants. Dans un premier temps, l'élargissement de l'échantillon à l'ensemble des données disponibles permettrait d'améliorer la représentativité et la fiabilité des modèles. Par ailleurs, l'intégration de techniques plus avancées, comme XGBoost ou l'analyse de texte par des méthodes de traitement du langage naturel (NLP), pourrait enrichir la qualité prédictive. Enfin, une attention particulière devra être portée à l'équité algorithmique et à la validation des modèles dans un cadre réel, en vue d'une application opérationnelle au sein des services clients ou des institutions financières.